

Projekt

**„Prognozowanie sprzedaży i analiza ryzyka z wykorzystaniem
symulacji Monte Carlo”.**

1. Wstęp

Współczesne firmy funkcjonują w warunkach dużej zmienności otoczenia gospodarczego, co powoduje konieczność stosowania narzędzi umożliwiających przewidywanie przyszłych zjawisk. Prognozowanie stanowi jeden z kluczowych elementów wspierających proces podejmowania decyzji w biznesie, logistyce oraz analizie danych.

Dynamiczny rozwój technologii informatycznych w głównej mierze AI sprawił, że tradycyjne metody prognozowania zostały rozszerzone o zaawansowane systemy analityczne, umożliwiające przetwarzanie dużych zbiorów danych oraz wykonywanie symulacji komputerowych. Dzięki temu możliwe stało się nie tylko przewidywanie wartości przyszłych, ale również analiza wielu alternatywnych scenariuszy rozwoju sytuacji.

2. Cel i zakres pracy

Celem pracy jest analiza możliwości wykorzystania narzędzi informatycznych oraz symulacji komputerowych w procesie prognozowania sprzedaży.

Cele szczegółowe:

- opracowanie modelu prognozowania sprzedaży,
- zastosowanie symulacji komputerowych do oceny ryzyka,
- porównanie różnych narzędzi analitycznych,
- ocena przydatności podejścia wieloplatformowego.

Zakres pracy obejmuje analizę danych sprzedażowych pochodzących z publicznego zbioru danych Superstore.

3. Dane badawcze

W pracy wykorzystano zbiór danych:

Superstore Dataset ze strony Kaggle <https://www.kaggle.com/datasets/vivek468/superstore-dataset-final>

Dane zawierają m.in.:

- Order ID – identyfikator zamówienia
- Order Date – data zamówienia
- Sales – wartość sprzedaży
- Profit – zysk
- Quantity – liczba produktów
- Discount – rabat

Dane zostały zagregowane do poziomu miesięcznego w celu utworzenia szeregu czasowego.

```

1 import pandas as pd
2 import matplotlib.pyplot as plt
3
4 # wczytanie danych
5 df = pd.read_csv(filepath_or_buffer: "Superstore.csv", encoding='cp1252')
6
7 # podgląd danych
8 pd.set_option(*args: 'display.width', None)
9 print(df.head())
10
11 # konwersja daty
12 df["Order Date"] = pd.to_datetime(df["Order Date"])
13
14 # ustawienie daty jako indeks
15 df.set_index(keys="Order Date", inplace=True)
16
17 # agregacja miesięczna (suma sprzedaży dla każdego miesiąca)
18 monthly_sales = df["Sales"].resample("ME").sum()
19
20 # podgląd danych
21 print(monthly_sales.head())

```

```

Order Date
2014-01-31    14236.895
2014-02-28     4519.892
2014-03-31    55691.009
2014-04-30    28295.345
2014-05-31    23648.287
Freq: ME, Name: Sales, dtype: float64

```

Screen_Python 2: 5 elementów szeregu czasowego


Screen_Python 1: Kod utworzenia szeregu czasowego.

```

20 # podgląd danych
21 print(monthly_sales.head())
22
23 plt.figure()
24 plt.plot(*args: monthly_sales.index, monthly_sales.values)
25
26 plt.title("Sprzedaż w czasie (agregacja miesięczna)")
27 plt.xlabel("Data")
28 plt.ylabel("Sprzedaż")
29
30 plt.show()

```

Screen_Python 3: Wizualizacja Sprzedaż w czasie.



Screen_Python 4: Wykres "Sprzedaż w czasie (agregacja miesięczna)"

Wykres przedstawia zmiany wartości sprzedaży w czasie w ujęciu miesięcznym. Na podstawie obserwacji można zauważyć zmienność poziomu sprzedaży w kolejnych okresach oraz potencjalne występowanie trendu. Agregacja danych pozwala na ograniczenie wpływu pojedynczych transakcji oraz lepsze zobrazowanie ogólnych tendencji w danych.

4. Metodyka badawcza

W pracy zastosowano podejście wielonarzędziowe obejmujące:

- modele statystyczne,
- uczenie maszynowe,
- analizę eksploracyjną danych,

- symulacje komputerowe.

Wykorzystane narzędzia:

- Python – modelowanie i symulacje,
- R – analiza szeregów czasowych,
- Microsoft Excel – raportowanie i wizualizacja,
- Statistica – analiza statystyczna.

5. Modelowanie w Pythonie

W pierwszym etapie wykonano budowę modelu prognostycznego sprzedaży. Zastosowano model regresji liniowej jako podstawę predykcji trendu.

```
38 # zamiana indeksu dat na liczby (czas jako zmienna niezależna)
39 monthly_sales = monthly_sales.reset_index()
40 monthly_sales["time_index"] = np.arange(len(monthly_sales))
41
42 # zmienne do modelu
43 X = monthly_sales[["time_index"]] # czas
44 y = monthly_sales["Sales"]       # sprzedaż
45
46 # budowa modelu regresji liniowej
47 model = LinearRegression()
48 model.fit(X, y)
49
50 # prognoza dla istniejących danych (dopasowanie)
51 monthly_sales["forecast"] = model.predict(X)
52
53 # prognoza na przyszłość (np. 3 miesiące do przodu)
54 future_periods = 3
55 future_index = np.arange(len(monthly_sales), len(monthly_sales) + future_periods)
56
57 future_df = pd.DataFrame({"time_index": future_index})
58
59 future_forecast = model.predict(future_df)
60
61 print("Prognoza na kolejne miesiące:")
62 print(future_forecast.round(2))
```

Screen_Python 5: Kod model regresji.


W celu wyznaczenia prognozy sprzedaży zastosowano model regresji liniowej, w którym zmienną niezależną był czas (indeks kolejnych miesięcy), natomiast zmienną zależną wartość sprzedaży.

Model został dopasowany do danych historycznych, a następnie wykorzystany do wyznaczenia prognozy na kolejne okresy.

Na podstawie modelu regresji liniowej wyznaczono prognozę sprzedaży na kolejne trzy okresy. Otrzymane wartości wskazują na kontynuację trendu wzrostowego, co może sugerować stabilny rozwój analizowanego zjawiska.

```
Prognoza na kolejne miesiące:
[69957.54 70859.54 71761.55]
```

Screen_Python 6: Prognoza sprzedaży na kolejne trzy miesiące.



Screen_Python 7: Wykres modelu


5.1. Symulacja Monte Carlo

W celu analizy niepewności zastosowano symulację Monte Carlo, polegającą na generowaniu wielu losowych scenariuszy wokół wartości prognozowanej.

```
81 #Symulacja Monte Carlo
82
83 n_simulations = 1000
84 std_dev = monthly_sales["Sales"].std()
85 base_forecast = future_forecast[0]
86
87 # symulacja
88 simulations = np.random.normal(base_forecast, std_dev, n_simulations)
89
90 # usunięcie wartości ujemnych
91 simulations = np.where(simulations < 0, x: 0, simulations)
92 simulations = np.round(simulations, decimals: 2)
93
94 # statystyki
95 print("Średnia:", round(np.mean(simulations), 2))
96 print("Minimum:", round(np.min(simulations), 2))
97 print("Maksimum:", round(np.max(simulations), 2))
```

```
Średnia: 69536.36
Minimum: 0.0
Maksimum: 169319.78
```

Screen_Python 8: Symulacja Monte Carlo.



Screen_Python 9: histogram symulacja Monte Carlo.

Wyniki przeprowadzonej symulacji Monte Carlo wskazują, że średnia prognozowana wartość wynosi około **69 595,12**, co można interpretować jako najbardziej typowy scenariusz uzyskiwany w analizie.

Jednocześnie uzyskany zakres wartości symulowanych jest bardzo szeroki – od **0,00 do 147 199,81**, co świadczy o dużej zmienności możliwych scenariuszy. Oznacza to, że prognozowana wartość może istotnie różnić się w zależności od przyjętych losowych warunków.

Warto zauważyć, że minimalna wartość równa zero wskazuje na możliwość wystąpienia skrajnie niekorzystnego scenariusza, w którym wynik jest bardzo niski. Wartości ujemne w symulacji zostały wyeliminowane w poprawionej wersji modelu jako nielogiczne ekonomicznie.

Uzyskane wyniki wskazują, że rzeczywista wartość sprzedaży może różnić się od prognozy bazowej w określonym zakresie. Symulacja pozwala zatem lepiej przygotować się na różne warianty rozwoju sytuacji i wspiera proces podejmowania decyzji.

5.2. Scenariusze decyzyjne

W celu rozszerzenia analizy prognostycznej opracowano trzy scenariusze rozwoju sytuacji: pesymistyczny, realistyczny oraz optymistyczny. Scenariusze zostały wyznaczone na podstawie prognozy bazowej, przy założeniu zmiany wartości sprzedaży o $\pm 10\%$. Takie podejście pozwala na uwzględnienie niepewności oraz lepsze przygotowanie na różne warianty przyszłych zdarzeń.

Przyjęcie odchylenia na poziomie $\pm 10\%$ wynika z potrzeby stworzenia prostych i interpretowalnych scenariuszy analitycznych. W praktyce analitycznej oraz biznesowej często stosuje się takie podejście jako punkt wyjścia do oceny wrażliwości modelu. Wartość 10% stanowi kompromis pomiędzy zbyt małą zmianą, która nie wnosi istotnych informacji, a zbyt dużą, która mogłaby prowadzić do nierealistycznych założeń.

```
109 #Tabela scenariuszy
110 base = future_forecast[0]
111
112 scenarios = {
113     "Pesymistyczny (-10%)": round(base * 0.9, 2),
114     "Realistyczny": round(base, 2),
115     "Optymistyczny (+10%)": round(base * 1.1, 2)
116 }
117
118 for key, value in scenarios.items():
119     print(key, ":", value)
```

Pesymistyczny (-10%) :	62961.78
Realistyczny :	69957.54
Optymistyczny (+10%) :	76953.29

Screen_Python 10: Kod tworzący tabelę scenariuszy biznesowych.

Uzyskane wyniki wskazują, że analizowany szereg czasowy sprzedaży charakteryzuje się wyraźnym trendem wzrostowym, co zostało potwierdzone zarówno przez model regresji liniowej, jak i prognozę wartości przyszłych. Prognoza bazowa sugeruje dalszy wzrost sprzedaży w kolejnych okresach, co może świadczyć o stabilnym rozwoju analizowanego przedsiębiorstwa lub rosnącym popycie na oferowane produkty.

Wyniki symulacji Monte Carlo pokazują jednak, że mimo pozytywnego trendu istnieje istotna niepewność co do przyszłych wartości. Szeroki zakres możliwych wyników wskazuje, że

rzeczywista sprzedaż może znacząco odbiegać od prognozy, co podkreśla konieczność uwzględniania ryzyka w analizie.

Dodatkowo zastosowanie scenariuszy (pesymistycznego, realistycznego i optymistycznego) pozwala określić potencjalny zakres zmian oraz lepiej przygotować się na różne warianty rozwoju sytuacji.


Otrzymane wyniki potwierdzają, że prognozowanie wspierane narzędziami informatycznymi oraz symulacjami komputerowymi umożliwia nie tylko przewidywanie przyszłych wartości, ale również kompleksową ocenę ryzyka i niepewności.

6. Analiza w R

W odróżnieniu od analizy przeprowadzonej w Pythonie, w środowisku R skupiono się na eksploracyjnej analizie szeregu czasowego poprzez jego dekompozycję. Pozwoliło to na identyfikację składowych danych i lepsze zrozumienie mechanizmu zmian sprzedaży. Analiza ta umożliwia lepsze zrozumienie struktury danych oraz identyfikację czynników wpływających na zmienność sprzedaży.

```
1 library(dplyr)
2 # wczytanie danych
3 setwd("D:/Projekt_prognowanie_symulacja")
4
5
6 data <- read.csv("Superstore.csv", fileEncoding="latin1")
7
8 data$Order.Date <- as.Date(data$Order.Date, format="%m/%d/%Y")
9
10 # agregacja miesięczna
11 monthly <- data %>%
12   group_by(format(Order.Date, "%Y-%m")) %>%
13   summarise(Sales = sum(Sales))
14
15 # konwersja do ts
16 ts_data <- ts(monthly$Sales, frequency=12)
17
18 # dekompozycja
19 decomp <- decompose(ts_data)
20
21 plot(decomp)
```

Screen_RStudio 1:Kod programu "Dekompozycja szeregu czasowego"



Screen_RStudio 2: Składowe szeregu czasowego sprzedaży (trend, sezonowość, losowość).

Na podstawie dekompozycji szeregu czasowego można zaobserwować wyraźny trend wzrostowy analizowanej sprzedaży. Składnik trendu wskazuje na stopniowy wzrost wartości sprzedaży w czasie, co może świadczyć o rozwoju działalności lub zwiększającym się popycie. Składnik sezonowy wykazuje powtarzalne wahania w kolejnych okresach, co sugeruje występowanie sezonowości w danych. Oznacza to, że w określonych miesiącach sprzedaż systematycznie rośnie lub spada.

Składnik losowy przedstawia nieregularne odchylenia od trendu i sezonowości, co wskazuje na wpływ czynników przypadkowych, takich jak pojedyncze duże zamówienia lub zdarzenia jednorazowe.


Przeprowadzona analiza pozwala stwierdzić, że badany szereg czasowy zawiera zarówno komponent trendu, jak i sezonowości, co uzasadnia stosowanie metod prognostycznych uwzględniających te elementy.

Wyniki dekompozycji są spójne z wcześniejszą analizą regresyjną oraz symulacją Monte Carlo, potwierdzając występowanie trendu wzrostowego oraz zmienności danych.

6.1. Autokorelacja ACF

Autokorelacja została wykorzystana w celu oceny zależności pomiędzy wartościami szeregu czasowego w kolejnych okresach. Analiza pozwala określić, czy wcześniejsze obserwacje mają wpływ na przyszłe wartości, co jest istotne w kontekście prognozowania.

Występowanie autokorelacji wskazuje na istnienie struktury w danych, co uzasadnia zastosowanie metod prognostycznych.



Screen_RStudio 3: Wykres autokorelacji ACF.

Lag (opóźnienie) oznacza liczbę okresów, o które przesuwana jest obserwacja w czasie w celu porównania jej z wartością bieżącą. W analizie autokorelacji lag pozwala określić, jak silnie wartości szeregu czasowego są powiązane z ich wcześniejszymi obserwacjami.

Analiza autokorelacji wykazała istotną zależność pomiędzy kolejnymi obserwacjami szeregu czasowego, szczególnie dla opóźnienia równego jednemu okresowi, co oznacza wpływ poprzednich wartości na bieżącą sprzedaż.

Dodatkowo zaobserwowano wyraźny wzrost autokorelacji dla opóźnienia odpowiadającego około 12 okresom, co wskazuje na występowanie sezonowości rocznej.

Uzyskane wyniki potwierdzają, że analizowany szereg czasowy posiada strukturę zależności, co uzasadnia zastosowanie metod prognostycznych.

7. Excel


W arkuszu kalkulacyjnym przeprowadzono analizę danych w celu ich wizualizacji oraz prezentacji w formie przystępnej dla użytkownika biznesowego. Wykorzystano tabelę przestawną do agregacji danych sprzedażowych oraz wykres liniowy do przedstawienia trendu w czasie.

Dodatkowo zastosowano prostą prognozę liniową, która umożliwia szybkie oszacowanie przyszłych wartości bez konieczności stosowania zaawansowanych narzędzi analitycznych.

Analiza w Excelu stanowi uzupełnienie bardziej zaawansowanych metod zastosowanych w Pythonie i R, pełniąc rolę narzędzia wspierającego interpretację wyników oraz komunikację danych.

2014	484247,50	2016	609205,60
sty	14236,90	sty	18542,49
lut	4519,89	lut	22978,82
mar	55691,01	mar	51715,88
kwi	28295,35	kwi	38750,04
maj	23648,29	maj	56987,73
cze	34595,13	cze	40344,53
lip	33946,39	lip	39261,96
sie	27909,47	sie	31115,37
wrz	81777,35	wrz	73410,02
paź	31453,39	paź	59687,75
lis	78628,72	lis	79411,97
gru	69545,62	gru	96999,04
2015	470532,51	2017	733215,26
sty	18174,08	sty	43971,37
lut	11951,41	lut	20301,13
mar	38726,25	mar	58872,35
kwi	34195,21	kwi	36521,54
maj	30131,69	maj	44261,11
cze	24797,29	cze	52981,73
lip	28765,33	lip	45264,42
sie	36898,33	sie	63120,89
wrz	64595,92	wrz	87866,65
paź	31404,92	paź	77776,92
lis	75972,56	lis	118447,83
gru	74919,52	gru	83829,32
2016	609205,60	Suma końcowa	2297200,86

Screen Excel 1: Tabela przestawna "Sprzedaż w latach 2014-2017.



Screen Excel 2: Wykres sprzedaży w latach 2014 - 2017.

Sprzedaż (Sales)	
Średnia	229,8580008
Błąd standardowy	6,234321582
Mediana	54,49
Tryb	12,96
Odchylenie standardowe	623,2451005
Wariancja próbki	388434,4553
Kurtoza	305,3117532
Skośność	12,97275234
Zakres	22638,036
Minimum	0,444
Maksimum	22638,48
Suma	2297200,86
Licznik	9994

Screen Excel 3: Statystyka opisowa sprzedaży zrobiona przy wykorzystaniu Solver.

Na wykresie przedstawiono miesięczne wartości sprzedaży w latach 2014–2017. Dane charakteryzują się znaczną zmiennością w czasie, jednak widoczny jest ogólny trend wzrostowy. W celu jego określenia zastosowano linię trendu wyznaczoną za pomocą **regresji liniowej**, której równanie ma postać: $y = 902,01x + 25759$.

Dodatni współczynnik kierunkowy wskazuje, że przeciętna wartość sprzedaży rośnie o około 902 jednostki w każdym kolejnym okresie. Oznacza to systematyczny wzrost sprzedaży w analizowanym przedziale czasowym.

Należy jednak zauważyć, że model liniowy stanowi uproszczenie rzeczywistości – nie uwzględnia sezonowości ani krótkookresowych wahań, które są widoczne na wykresie. W związku z tym linia trendu dobrze obrazuje ogólną tendencję, lecz ma ograniczoną dokładność prognostyczną. Excel pełni funkcję narzędzia prezentacyjnego i wspierającego podejmowanie decyzji.

Spis treści

1.	Wstęp.....	2
2.	Cel i zakres pracy	2
3.	Dane badawcze.....	2
4.	Metodyka badawcza.....	3
5.	Modelowanie w Pythonie	4
5.1.	Symulacja Monte Carlo	5
5.2.	Scenariusze decyzyjne	6
6.	Analiza w R	7
6.1.	Autokorelacja ACF	8
7.	Excel.....	9